

مقدمه ای بر یادگیری ماشین 25737

دانشگاه صنعتی شریف

گروه 1

دانشکده مهندسی برق

مدرس: سید جمال الدین گلستانی

نیمسال بهار 97-98

### تکلیف شماره 3

موعد تحویل: یکشنبه 98/1/18 ساعت 10 صبح

برای مطالعه - قسمت‌های زیر از کتاب درسی تا کنون مورد بحث قرار گرفته است:

- فصل 1 تا 4 به طور کامل
- فصل 5، بخش 5.2
- فصل 6، بخش‌های 6.2 و 6.3 و 6.4 (به جز corollary 6.4 و Theorem 6.6)
- فصل 9 به طور کامل
- فصل 11 بخش 11.2 (به جز 11.2.4)
- فصل 15 تا ابتدای 15.1.1
- فصل 20 بخش‌های 20.1، 20.2 و 20.3 (به جز قضایای 20.2، 20.3 و 20.5)

این تکلیف تنها شامل سوالات تئوری است.

#### سوال T8

الف - بردارهای  $r, u, v \in \mathbb{R}^n$  مفروض اند. یک شبکه عصبی با ورودی  $x \in \mathbb{R}^n$  و با استفاده از تابع  $\sigma = \text{sign activation}$  طراحی کنید به نحوی که خروجی آن  $N(x)$  دو بیت باینری به صورت

$$N(x) = \begin{cases} 00 & S = -3 \\ 01 & S = -1 \\ 10 & S = 1 \\ 11 & S = 3 \end{cases}$$

باشد، که در اینجا  $S$  به صورت زیر تعریف شده است:

$$S = \text{sign}(r^T x + b) + \text{sign}(u^T x + c) + \text{sign}(v^T x + d)$$

$d, c, b$  اعداد حقیقی مفروضی می باشند. توجه کنید که در تعریف خروجی  $N(x)$ ، 0 و 1 جایگزین مقادیر معمول 1- و 1+ شده‌اند و می‌توانید به جای 0 و 1، -1 و 1+ قرار دهید.

در شبکه ای که طراحی می‌کنید، برای گره‌های با ورودی ثابت، ورودی را برابر 1 فرض کنید. در طرح خود سعی کنید که از کمترین تعداد گره و لایه ممکن استفاده کنید. وزن هر لینک را بر روی شکل (بر حسب  $r, u, v, b, c, d$ ) مشخص نمایید.

### سوال T9

مساله 9 از فصل 6 کتاب

### سوال T10

مساله 1 از فصل 6 کتاب

### سوال T11

در یک مساله Binary classification فرض کنید  $\chi = \mathbb{R}^2$  و  $H$  مجموعه ای از فرضیه های مبتنی بر axis aligned rectangles یا مستطیل های موازی محورهای مختصات باشد. به عبارت دیگر، فرض کنید

$$H = \{h_{(a_1, a_2, b_1, b_2)} : a_1 < a_2, b_1 < b_2\}$$

که در آن

$$h_{(a_1, a_2, b_1, b_2)}(x^1, x^2) = \begin{cases} 1 & a_1 \leq x^1 \leq a_2, b_1 \leq x^2 \leq b_2 \\ 0 & \text{Otherwise} \end{cases}$$

به یاد آورید که  $H$  در تعریف فوق؛ همان مجموعه فرضیه هایی است که در مثال مربوط به حدس طعم انبه مورد استفاده قرار گرفت.

الف – بخش 6.3.3 کتاب را که در آن  $VCdim(H)$  بدست آمده است، مطالعه کنید.

ب – با توجه به قضیه 6.8، یک حد بالایی و حد پایینی بر روی  $m_H(\epsilon, \delta)$  به دست آورید.

ج – با توجه به اینکه در حد بالایی و پایینی بدست آمده در بند قبل از ضرایب  $C_1$  و  $C_2$  استفاده شده است که مقادیر آنها مشخص نیست، توضیح دهید که حدهای بدست آمده چه فایده ای دارد. به عبارت بهتر، درحالیکه ضرایب نامشخص  $C_1$  و  $C_2$  می توانند هر مقداری داشته باشند، این حدهای بالایی و پایینی حاوی چه اطلاعات سودمندی هستند؟

### سوال T12

الف – مساله 3 از فصل 2 کتاب. تنها بندهای 1 و 2 مساله.

در این مساله، برای مساله مفروض در سوال T11، یعنی با فرض  $\chi = \mathbb{R}^2$  و  $H$  تعریف شده در سوال T11، با روش بررسی مستقیم (یعنی بدون استفاده از  $VCdim(H)$  و قضیه 6.8) نشان می دهید که هرگاه تعداد نمونه های آموزشی در نامساوی  $m > \frac{4 \log^4 / \delta}{\epsilon}$  صدق نماید و شرط realizability برقرار باشد، در آنصورت با احتمال حداقل  $1 - \delta$ ، ریسک واقعی فرضیه انتخاب شده بوسیله الگوریتم پیشنهادی در مساله (که یک الگوریتم ERM است) از  $\epsilon$  کمتر خواهد بود:  $L_D(h_S) \leq \epsilon$

ب – آیا رابطه  $m > \frac{4 \log^4 / \delta}{\epsilon}$  بیانگر یک حد بالایی یا یک حد پایینی بر روی  $m_H(\epsilon, \delta)$  است؟ این حد را با حد مشابه بدست آمده در سوال T11 مقایسه کنید.

### سوال T13

در متن درس توضیح دادیم که در صورتی که در یک مساله binary classification، توزیع  $\mathcal{D}$  معلوم باشد، در آن صورت روش تخمین زیر (که به تخمین Bayes موسوم است) به کمترین مقدار ریسک واقعی

$$f(x) = \begin{cases} 1 & \text{Prob}[y = 1 | x] \geq 0.5 \\ 0 & \text{Prob}[y = 1 | x] < 0.5 \end{cases}$$

True Risk منجر می‌گردد که آن را  $\epsilon_{Bayes}$  می‌نامیم.

با نوشتن رابطه ریاضی لازم، ثابت کنید که ریسک واقعی فرضیه فوق  $L_D(f)$  نسبت به ریسک واقعی هر فرضیه  $h$  دیگر  $L_D(h)$  کمتر یا مساوی است:  $\epsilon_{Bayes} = L_D(f) \leq L_D(h), \forall h$

توضیح: می‌دانیم که در مساله Binary classification، تابع ریسک به صورت

$$l(h, (x, y)) = \begin{cases} 1 & h(x) \neq y \\ 0 & h(x) = y \end{cases}$$

تعریف می‌شود.

### سوال T14

مجموعه فرضیه  $H$  با  $|H|$  محدود و بر روی دامنه  $\mathcal{X}$  مفروض است. مجموعه label ها را  $\mathcal{Y}$  می‌نامیم. تابع ریسک  $l(h, (x, y))$  همواره مقداری بین 0 و 1 اختیار می‌کند. یک مجموعه داده آموزشی  $S$  شامل  $m$  نقطه به صورت  $i.i.d$  و بر اساس توزیع دلخواه  $\mathcal{D}$  در اختیار ما قرار دارد.

الف – یک فرضیه  $h$  به طور رندم از مجموعه  $H$  اختیار می‌کنیم و  $L_S(h)$  را بدست آورده، آن را  $\eta$  می‌نامیم:  $L_S(h) = \eta$ . فرض کنید  $0 < \eta < 0.1$  باشد. مایلیم بدانیم احتمال اینکه  $L_D(h)$  از  $2\eta$  بیشتر باشد چقدر است، بهترین حد بالایی را که می‌توانید بر روی  $\text{Prob}[L_D(h) > 2\eta]$  بدست آورید.

ب – اکنون فرض کنید یک الگوریتم یادگیری  $A$  بر روی مجموعه  $H$  و با استفاده از داده آموزشی  $S$  عمل می‌کند و فرضیه  $A(s) = h_s \in H$  را بدست می‌آورد. ( $A$  ضرورتاً بر اساس رویکرد ERM کار نمی‌کند)، برای  $h_s$  بدست آمده داریم  $L_S(h_s) = \gamma$ . باز هم فرض می‌کنیم  $0 < \gamma < 0.1$ . بند الف را برای  $h_s$  تکرار کنید، یعنی بهترین حد بالایی که می‌توانید بر روی  $\text{Prob}[L_D(h_s) > 2\gamma]$  بدست آورید.

ج – حال فرض کنید مساله یادگیری مورد بحث در بند الف و ب به صورت Binary classification است یعنی  $\mathcal{Y} = \{\pm 1\}$ . همچنین فرض کنید به نحوی بفهمیم که برای توزیع  $\mathcal{D}$ ،  $\epsilon_{Bayes}$  برابر  $3\eta$  است. در این صورت آیا پاسخ شما در بند الف دچار تغییر می‌شود؟ چگونه؟

د – اگر پاسخ شما در بند ج نسبت به بند الف تغییر می‌یابد، آیا این موضوع به معنی آن است که نامساوی Hoeffding (که مبنای نتیجه گیری شما در بند الف بود)، دیگر در بند ج برقرار نیست؟ توضیح دهید.