

سوال T15

$$\min_{w \in \mathbb{R}^d} L_s(w) = \frac{1}{m} \sum_{i=1}^m |w^T x_i - y_i| \quad x_i \in \mathbb{R}^d, y_i \in \mathbb{R}$$

(الف) خیر، مسئله ی بهینه سازی خطی باید فرم زیر را داشته باشد:


$$\min f_0(w) = c^T w$$

$$\text{s.t. } e_i^T w + r_i \leq 0$$

$$h_i^T w + q_i = 0$$

(مساوات شلخته)

اما در مسئله ما، تابع هدف ترکیبی از چندین Hyperplane است و یک خط برای بهینه سازی نیست. همچنین مسئله غیر مقعر است و نیازی به یک کردن این که قیود خطی هستند نیست.



دفعه ی 1 بعدی

$$\forall \alpha \in [0, 1] \\ \forall w_1, w_2 \in \mathbb{R}^d : f(\alpha w_1 + (1-\alpha)w_2)$$

(ب) بله - کافی است نشان دهیم:

$$\leq \alpha f(w_1) + (1-\alpha) f(w_2)$$

برای این کار، مسئله را اینگونه می نویسیم:

$$\min \underbrace{\frac{1}{m} |\langle w, x_1 \rangle - y_1|}_{f_1(w)} + \underbrace{\frac{1}{m} |\langle w, x_2 \rangle - y_2|}_{f_2(w)} + \dots + \underbrace{\frac{1}{m} |\langle w, x_m \rangle - y_m|}_{f_m(w)}$$

چون ضرایب ضرب شده در توانی هگلی $\frac{1}{m}$ ، مثبت هستند / کافی است نشان دهیم هر یک از $f_i(w)$ ها محدب است:

$$\begin{aligned} f_i(\alpha w_1 + (1-\alpha)w_2) &= |\langle \alpha w_1 + (1-\alpha)w_2, x_i \rangle - y_i| \\ &= |\langle \alpha w_1, x_i \rangle + \langle (1-\alpha)w_2, x_i \rangle - y_i| \\ &= |\alpha \langle w_1, x_i \rangle + (1-\alpha) \langle w_2, x_i \rangle - y_i| \\ &= |\alpha \langle w_1, x_i \rangle + (1-\alpha) \langle w_2, x_i \rangle - \alpha y_i - (1-\alpha) y_i| \\ &= |\alpha (\langle w_1, x_i \rangle - y_i) + (1-\alpha) (\langle w_2, x_i \rangle - y_i)| \\ &\leq \alpha |\langle w_1, x_i \rangle - y_i| + (1-\alpha) |\langle w_2, x_i \rangle - y_i| \quad (\alpha, 1-\alpha \geq 0) \\ &\leq \alpha f_i(w_1) + (1-\alpha) f_i(w_2) \end{aligned}$$

پس تمام $f_i(w)$ محدب هستند پس $\frac{1}{m} \sum_{i=1}^m f_i(w)$ نیز محدب است.

ج) خیر، در رشته‌های $f_i(w)$ ها، تابع هدف مشتق پذیر نیست.

به طور مثال در نقطه $w = (\frac{y_1}{x_1^2}, 0, 0, \dots, 0)$ مشتق پذیر نیست.
(منظور از x_1' ، مؤلفه اول x_1 است.)

$$\textcircled{1} \min_{w \in \mathbb{R}^{d+1}} |f(w)| \quad \text{معادل} \quad \textcircled{2} \min c \quad \text{s.t.} \quad \begin{aligned} c &\geq f(w) \\ c &\geq -f(w) \end{aligned} \quad \textcircled{3}$$

در ابتدا فرض می‌کنیم w^* نقطه بهینه مسئله بهینه سازی $\textcircled{1}$ باشد در این صورت خواهد داشت:

$$\forall w \in \mathbb{R}^d: |f(w^*)| \leq |f(w)|$$

در نتیجه برای w^* نیز برقرار است، پس داریم:

$$|f(w^*)| \leq |f(w^*)| \Rightarrow \underbrace{-|f(w^*)|}_{c^*} \leq f(w^*) \leq \underbrace{|f(w^*)|}_{c^*}$$

$$\Rightarrow \begin{cases} f(w^*) \leq c^* \\ -f(w^*) \leq c^* \end{cases}$$

در نتیجه (w^*, c^*) در قید مسئله ② صدق می کند.

فرض خلف: فرض می کنیم (w^*, c^*) جواب بهینه مسئله ② نباشند در نتیجه (\hat{w}, \hat{c})

$$\begin{cases} \hat{c} \geq f(\hat{w}) \\ \hat{c} \geq -f(\hat{w}) \end{cases} \Rightarrow \hat{c} < c^* = |f(w^*)|$$

ای وجود دارد که:

$$\Rightarrow |f(\hat{w})| < |f(w^*)|$$

با فرض اینکه w^* جواب بهینه مسئله ① است رتناقض است. پس فرض خلف باطل و حکم صادق است.

حال برای تبدیل به طریق مشابه بالا اثبات می شود که

$$\min_w |f_1(w)| + |f_2(w)| = \min c$$

$$c \geq f_1(w) + f_2(w)$$

$$c \geq f_1(w) - f_2(w)$$

$$c \geq -f_1(w) + f_2(w)$$

$$c \geq -f_1(w) - f_2(w)$$

در نتیجه برای M تابع به شکل مقابل خواهیم داشت:

$$\min_w \left(\left| \frac{f_1(w)}{m} \right| + \left| \frac{f_2(w)}{m} \right| + \dots + \left| \frac{f_m(w)}{m} \right| \right)$$

که معادل مسئله بهینه‌سازی زیر خواهد بود:

$$\min C$$

$$\text{s.t.} \quad C \geq \frac{f_1(w)}{m} + \frac{f_2(w)}{m} + \dots + \frac{f_m(w)}{m}$$

$$C \geq -\frac{f_1(w)}{m} + \frac{f_2(w)}{m} + \dots + \frac{f_m(w)}{m}$$

$$\vdots$$

$$C \geq -\frac{f_1(w)}{m} - \frac{f_2(w)}{m} - \dots - \frac{f_m(w)}{m}$$

در نتیجه مسئله بهینه‌سازی بالا شامل 2^m قید خواهد بود که هر کدام حالت مثبت و یا منفی می‌باشند.

از $\frac{f_i(w)}{m}$ ها خواهد بود که $f_i(w)$ برابر است با: $f_i(w) = \langle w, x_i \rangle - y_i$

$$\text{If } m \geq m_{ff}(\varepsilon) \xrightarrow[\text{D}]{\text{for every}} \mathbb{E}_{s \sim D^m} [L_D(A(s))] \leq \min_{h \in H} L_D(h) + \varepsilon$$

حال اگر m را بزرگتر از $m_{ff}(\varepsilon \delta)$ بگیریم، خواهیم داشت:

$$m \geq m_{ff}(\varepsilon \delta) \Rightarrow \mathbb{E}_{s \sim D^m} [L_D(A(s))] \leq \min_{h \in H} L_D(h) + \varepsilon \delta. \quad (*)$$

حال بر اساس نامساوی مارکوف خواهیم داشت:

$$\begin{aligned} L_D(A(s)) - \min_{h \in H} L_D(h) \geq 0 &\Rightarrow \mathbb{P}[L_D(A(s)) - \min_{h \in H} L_D(h) \geq \varepsilon] \\ &\leq \frac{\mathbb{E}[L_D(A(s)) - \min_{h \in H} L_D(h)]}{\varepsilon} = \frac{\mathbb{E}[L_D(A(s))] - \min_{h \in H} L_D(h)}{\varepsilon} \end{aligned}$$

$$\xrightarrow{(*)} \leq \frac{1}{\varepsilon} \cdot \varepsilon \delta = \delta$$


$$\Rightarrow \mathbb{P}[L_D(A(s)) - \min_{h \in H} L_D(h) \geq \varepsilon] \leq \delta$$

پس با احتمال $1 - \delta$ خواهیم داشت:

$$L_D(A(s)) \leq \min_{h \in H} L_D(h) + \varepsilon.$$

سوال T17

$$H' \subseteq H \rightarrow VCdim(H') \leq VCdim(H)$$



فرض کنید مجموعه C ، مجموعه ای باشد که H' بر آن غالب است و حال چون $H' \subseteq H$ است h های که در H' هستند نه تمام حالت های مقداری C را پوشش می دهند، در H نیز قرار دارند پس H نیز بر آن ها غالب است و چون H دارای توابع بیشتری نسبت به H' است پس ممکن است C' ای با $|C'| > |C|$ وجود داشته باشد که H بر آن ها غالب است اما H' نیست، در نتیجه خواهیم داشت:

$$VCdim(H') \leq VCdim(H)$$

سوال T18

① Hard SVM: $w^* = \underset{w}{\operatorname{argmin}} \|w\|^2$
s.t. $y_i w^T x_i \geq 1, i=1, 2, \dots, m$

② Soft SVM: $\hat{w} = \min_w \frac{\lambda}{2} \|w\|^2 + \frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i w^T x_i)$
 $i=1, 2, 3, \dots, m$

می خواهیم اثبات کنیم که برای وقتی که مجموعه آموزشی معنی S به صورت خطی قابل جداسازی باشد جواب مسئله های بهینه سازی بالا با هم برابرند.

بدین منظور فرض می کنیم که w^* ، جواب بهینه مسئله Hard SVM باشد، حال

ادعا می‌کنیم در صورتی که S ویژگی مورد نظر را داشته باشد، w^* جواب مسئله Soft-SVM نیز می‌باشد. در مسئله (2) چون قیدی نداریم در نتیجه w^* جزء کاندیدهاست جواب مسئله خواهد بود.

• بهمان خلف: فرض می‌کنیم w^* جواب مسئله (1) نیست در نتیجه \hat{w} وجود دارد که دارای کمترین $\frac{\lambda}{2} \|\hat{w}\|^2 + L_s^{hinge}(w)$ بین تمام w هاست، پس خواهیم داشت: (در حالت)

(I). حالت اول، حالتی است که $L_s^{hinge}(w)$ برای \hat{w} برابر با صفر باشد:

$$L_s^{hinge}(\hat{w}) = 0 \Rightarrow \frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i \hat{w}^T x_i) = 0 \Rightarrow y_i \hat{w}^T x_i \geq 1.$$

← مسئله (1) صدق می‌کند.

حال بایستیم به این مسئله (1) برای \hat{w} برابر است با 1، $y_i w^* x_i \geq 1$ خواهیم داشت:

$$\frac{\lambda}{2} \|\hat{w}\|^2 + \underbrace{\frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i \hat{w}^T x_i)}_0 < \underbrace{\frac{\lambda}{2} \|w^*\|^2 + \frac{1}{m} \sum_{i=1}^m L_s^{hinge}(w^*)}_0$$

$$\Rightarrow \|\hat{w}\|^2 < \|w^*\|^2 \Rightarrow \|\hat{w}\| < \|w^*\|$$

با فرض اینکه w^* جواب مسئله (I) است در تناقض است. پس حکم برقرار است.

(II) حالت دوم، حالتی که است نه در این $L_s^{hinge}(\hat{w}) \neq 0$ باشد:

$$\frac{\lambda}{2} \|\hat{w}\|^2 + \frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i \hat{w}^T x_i) < \frac{\lambda}{2} \|w^*\|^2 + \underbrace{\frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i w^{*T} x_i)}_0$$

$$\frac{\lambda}{2} \|\hat{w}\|^2 + \frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i \hat{w}^T x_i) \leq \frac{\lambda}{2} \|w^*\|^2$$

باتوجه به این که دو عبارت سمت چپ هر دو مثبت هستند پس خواهیم داشت:

$$\frac{\lambda}{2} \|\hat{w}\|^2 < \frac{\lambda}{2} \|w^*\|^2 \Rightarrow \|\hat{w}\| < \|w^*\| \quad (*)$$

حال λ خود را باتوجه به رابطه بالا به صورت زیر تعریف می‌کنیم:

$$\lambda = \frac{2}{m \|w^*\|^2} > 0$$

حال در نتیجه خواهیم داشت:

$$\frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i \hat{w}^T x_i) < \frac{\lambda}{2} (\|w^*\|^2 - \|\hat{w}\|^2) =$$

$$\frac{2}{m} \cdot \frac{1}{\|w^*\|^2}$$

$$\Rightarrow \sum_{i=1}^m \max(0, 1 - y_i \hat{w}^T x_i) < \frac{\|w^*\|^2 - \|\hat{w}\|^2}{\|w^*\|^2} < 1$$

$$\Rightarrow \forall i \in \{1, 2, \dots, m\} : \max(0, 1 - y_i \hat{w}^T x_i) < 1$$

$$\Rightarrow \forall i : 1 - y_i \hat{w}^T x_i < 1 \Rightarrow y_i \hat{w}^T x_i < 1$$

$$\Rightarrow \forall i : \boxed{0 < y_i \hat{w}^T x_i < 1}$$

حال رزسبه \hat{w} در فرم بهینه‌سازی Hard-svm زیر صق می‌کند:

$$\max_w \min_i \frac{1}{\|w\|} |w^T x_i|$$

$$s.t. \quad y_i \hat{w}^T x_i > 0, \quad i=1, 2, \dots, m$$

که فرم بهینه‌سازی بالا معادل فرم معادل مسئله بهینه‌سازی زیر است که همان Hard-SVM اصلی:

$$\min_w \|w\|^2 \quad \text{s.t.} \quad y_i w^T x_i \geq 1$$

پس \hat{w} کاندیدی جواب مسئله بهینه‌سازی بالا است که جواب مسئله w^* می‌باشد پس باید:

$$\|w^*\| < \|\hat{w}\|$$

به تابع هدف خواص داشت:

که با (*) در تناقض است پس فرض خلف باطل و حجم صادق است.

پس $\lambda = \frac{2}{m \|w^*\|^2} > 0$ وجود دارد که به ازای این جواب مسئله w^* بهینه‌سازی

soft-SVM و hard-SVM برای حالتی که به صورت خطی قابل جداسازی باشد

وجود دارد.

$$f(w) = \lambda \|w\|^2 + \frac{1}{2m} \sum_{i=1}^m (\langle w, \psi(x_i) \rangle - y_i)^2 \quad .1$$

برای بهینه سازی تابع هدف بالا
 Representer theorem داریم که جواب بهینه سازی تابع هدف بالا
 $\alpha \in \mathbb{R}^m$: $\sum_{i=1}^m \alpha_i \psi(x_i)$ برابر است با :

$$\begin{aligned} \langle w, \psi(x_i) \rangle &= \left\langle \sum_{j=1}^m \alpha_j \psi(x_j), \psi(x_i) \right\rangle = \sum_{j=1}^m \alpha_j \langle \psi(x_j), \psi(x_i) \rangle \\ &= \sum_{j=1}^m \alpha_j K(x_j, x_i) = \sum_{j=1}^m \alpha_j G_{ij} = (G\alpha)_i = \langle \alpha, G_{\cdot, i} \rangle \end{aligned}$$

$$\begin{aligned} \|w\|^2 &= \langle w, w \rangle = \left\langle \sum_{j=1}^m \alpha_j \psi(x_j), \sum_{k=1}^m \alpha_k \psi(x_k) \right\rangle \\ &= \sum_{j=1}^m \sum_{k=1}^m \alpha_j \alpha_k \langle \psi(x_j), \psi(x_k) \rangle = \sum_{j=1}^m \sum_{k=1}^m \alpha_j \alpha_k K(x_j, x_k) \\ &= \sum_{j=1}^m \sum_{k=1}^m \alpha_j \alpha_k G_{jk} = \alpha^T G \alpha. \end{aligned}$$

$$\min_w \lambda \|w\|^2 + \frac{1}{2m} \sum_{i=1}^m (\langle w, \psi(x_i) \rangle - y_i)^2 = \min_{\alpha} \lambda \alpha^T G \alpha + \frac{1}{2m} \sum_{i=1}^m (\langle \alpha, G_{\cdot, i} \rangle - y_i)^2$$

حال اگر :

$$\alpha^* = \min_{\alpha} \lambda \alpha^T G \alpha + \frac{1}{2m} \sum_{i=1}^m (\langle \alpha, G_{\cdot, i} \rangle - y_i)^2$$

$$\Rightarrow w^* = \sum_{i=1}^m \alpha_i^* \psi(x_i)$$

$$f(w) = \lambda \|w\|^2 + \frac{1}{2m} \sum_{i=1}^m (\langle w, \psi(x_i) \rangle - y_i)^2 \cdot 2$$

$$= \lambda w^T w + \frac{1}{2m} \sum_{i=1}^m (w^T \psi(x_i) - y_i)^2$$

$$\nabla_w f(w) = 0 \Rightarrow \nabla_w f(w) = 2\lambda w + \frac{1}{2m} \sum_{i=1}^m 2 \psi(x_i) (w^T \psi(x_i) - y_i)$$

$$\Rightarrow 2\lambda w^* + \frac{1}{m} \left(w^* \sum_{i=1}^m \psi(x_i) \psi(x_i)^T - \sum_{i=1}^m \psi(x_i) y_i \right) = 0$$

$$\Rightarrow \bullet X = (\psi(x_1) \quad \psi(x_2) \quad \dots \quad \psi(x_m))$$

$$\Rightarrow 2\lambda w^* + \frac{1}{m} (w^* X X^T - Y X) = 0$$

$$\Rightarrow 2m\lambda w^* + X X^T w^* = Y X$$

$$\Rightarrow (2m\lambda I + X X^T) w^* = Y X$$

$$w^* = \underbrace{(2m\lambda I + X X^T)^{-1}}_{\alpha^*} Y X$$

$$\Rightarrow \underline{\alpha^* = (2m\lambda I + X X^T)^{-1} Y}$$