

«بسم الله خدا»

حسن ابراهیمی - ۹۵۱۵۵۳۰۲

تغییر سی قسم

۱.

سوال T24

$$\begin{aligned} E_{S \sim D^m} [L_s(h)] &= E_{Z_i \sim D} \left[ \frac{1}{m} \sum_{i=1}^m \ell(h, z_i) \right] \\ &= \frac{1}{m} \sum_{i=1}^m E_{Z_i \sim D} [\ell(h, z_i)] = \frac{1}{m} \sum_{i=1}^m L_D(h) = L_D(h) \end{aligned}$$

سوال T25

$x, x' \in \{1, 2, \dots, N\}$ ,  $N \in \text{Integer Number}$

$K(x, x') = \min(x, x')$ , find  $\varphi: \{1, 2, \dots, n\} \rightarrow H_{\text{space}}$ .

نمایش  $\varphi$  را بدین صورت تعریف می‌کنیم به تعداد آن عدد طبیعی ورودی، ۱ قدر می‌دهیم.

و بقیه را صفر می‌گذاریم یعنی:

$$\varphi(i) = \begin{bmatrix} 1 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix} \in H$$

حال برای دو عدد دلخواه  $i$  و  $j$  ضرب داخلی آن‌ها برابر خواهد بود با:

$$\langle \varphi(i), \varphi(j) \rangle = \begin{bmatrix} 1 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix}^T \begin{bmatrix} 1 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix}$$

$$= \underbrace{1+1+\dots+1}_{\text{تعداد کوخپله بین } i \text{ و } j} + 0 + \dots = \min(i, j) = K(i, j)$$

تعداد کوخپله بین  $i$  و  $j$


$$h \in \{0,1\}^d \rightarrow \{0,1\}$$

1.

$$h(x_1, x_2, x_3, \dots, x_d) = 0 \text{ یا } 1$$

با توجه به اینکه ورودی ما برابر با  $d$  ی باشد پس  $2^d$  حالت مختلف برای ورودی خواهیم داشت که باینری classifier -  $h$  می تواند به هر کدام  $0$  یا  $1$  مقدار صفر یا یک بدهد.

حال برای ساختن درخت تصمیم گیری ساختار کافی است در هر گره  $0$  یا  $1$  مقدار داده به دلخواه بر اساس یکی از  $x_i$  ها که در ارتفاع  $h$  بالاتر تعریف شده است، چپ سازی انجام دهیم:



حالت ارتفاع صفت برابر با  $d+1$  خواهد بود چون با در مراحل بالا معیار نسبت داده شده یا با  $h$  برابر می شود یا نیاز است گره ها جدید اضافه کنیم که حالت  $d$  متباین نمی باشد. حال در بزرگ ها درخت با ارتفاع  $d+1$  تمام حالت ها ممکن ورودی که  $2^d$  حالت داشت وجود دارد و می توانیم بر اساس این که مقدار  $h$  با آن ها چیست به آن ها label مشاظر را بنویسیم و کاملاً  $h$  را پیاده سازی کنیم.

2.

ابتدا باید نشان دهیم که Decision Tree شامل توانایی است که می تواند تمام

حالت ها مقدار دهی به مجموعه ای به اندازه  $2^d$  را در  $\text{Domain} = \{0,1\}^d$  بپوشاند

یا به عبارتی shutter کند.



بدین منظور همانند حالت قبل، درختی با ارتفاع  $d+1$  را در نظر می‌گیریم که در هر سطح از آن گره‌ها ؟ قرار دارند. حال بزرگ‌ها این درخت که تعدادشان  $2^d$

است. تمام حالت‌ها  $(x_1, x_2, \dots, x_d)$  را دارد. حال می‌توانیم با label قرار دادن بدین بزرگ‌ها تمام حالت‌ها مختلف مقداردهی به این  $2^d$  عضو را داشته باشیم. وقت‌کنند هر حالت مقداردهی یک  $h$  را مشخص می‌کند در  $h$  یعنی  $D_T$  قرار دارد. در نتیجه  $2^{2^d}$  حالت مقداردهی متفاوت به این مجموعه در  $h$  وجود دارد پس:

$h$  shatters  $C$ . مقدار  $C$

حال از طرفی چون مجموعه‌ای بزرگ‌تر از  $2^d$  در Domain نداریم پس مجموعه‌ای به سائید  $2^d + 1$  وجود ندارد. در نتیجه VC dimension مجموعه توزیع Decision Tree برابر با  $2^d$  خواهد بود.

سوال T27

$x_1, x_2, x_3, x_4, y$

1 0 1 0 0  
1 1 0 0 0

0 0 1 1 0  
0 1 1 1 1

0 0 1 1 1

Information Gain

Gain

قدرتی نسبی



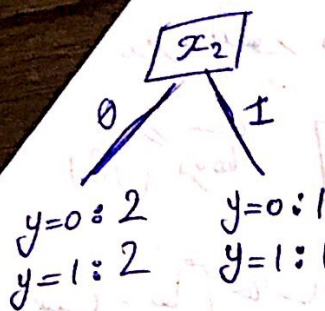
$y=0:1$   
 $y=1:2$

$y=0:2$   
 $y=1:1$

$$C(P_S[y=1]) = -\frac{3}{6} \log \frac{3}{6} - \frac{3}{6} \log \frac{3}{6} = -\log \frac{1}{2} = \log 2 = 1$$

$$\text{Gain}(S, x_1) = 1 + \left[ +\frac{1}{2} \left( \frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3} \right) + \frac{1}{2} \left( \frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3} \right) \right] = 0.081$$






$$C(P_S(y=1)) = -\frac{4}{6} \log \frac{4}{6} - \frac{2}{6} \log \frac{2}{6}$$

$$= -\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3} = 0.91$$


$$\text{Gain}(S, x_2) = 0.91 + \left[ \frac{4}{6} \left( \frac{2}{4} \log \frac{2}{4} + \frac{2}{4} \log \frac{2}{4} \right) + \frac{2}{6} \left( \frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2} \right) \right] = 0.91 + \frac{2}{3} \log \frac{1}{2} + \frac{1}{3} \log \frac{1}{2}$$

$$= 0.91 + \log \frac{1}{2} = 0.91 - \log 2 = -0.091$$




$$x_1 \text{ نباشد: } \text{Gain}(S, x_3) = 0.08$$

$$C(P_S[y=1]) = -\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3} = 0.91$$




$$\text{Gain}(S, x_4) = 0.91 + \left[ \frac{4}{6} \left( \frac{1}{4} \log \frac{1}{4} + \frac{3}{4} \log \frac{3}{4} \right) + \frac{2}{6} \left( \log 1 + \log 0 \right) \right] = 0.91 + \frac{-0.54}{3/2} = 0.36$$

خ4 بیشترین In form gain را دارد پس براساس این Split کنیم



وقتی x4 برابر با 0 است تمام داده های ای برابر با 1 دارند پس این برگ بزرگ می کشیم.



حال در مرحله بعد باید براساس x3 جداسازی انجام بدهیم

$$IG(S', x_3) = 0.5 \checkmark$$


$$IG(S', x_1) = IG(S', x_2) = -0.14$$

IG را داریم




در مرحله آخر بر اساس  $x_2$  split می‌کنیم.  
 زیرا جبراسازی کامل دارد و عددی که برای  $x_1$  انتخابه نیست.

داره  $S$  کاملاً جبراسازی می‌شود و رزقیه  $L_3(h_S) = 0$



$$y = \bar{x}_1 x_2 + \bar{x}_3 \bar{x}_2$$



$$L_3(h) = 0$$

(ج) نمابر 2 دلیل: 1- پیچیدگی محاسباتی زیاد 2- overfitting

پیدا کردن عبارت منطقی ای که  $S$  را بیان کند از لحاظ محاسباتی مشکل است همچنین می‌تواند تعداد زیادی عبارت منطقی وجود داشته باشد که  $S$  را توصیف دهد و پیدا کردن بهترین آن‌ها کار دشواری از لحاظ محاسباتی است.

همچنین با این کار مدل ما کاملاً بر داده آموزشی  $fit$  می‌شود و اندک احتمال overfitting بسیار بالا می‌رود.

سوال T28

برای مقدار  $\epsilon$  fixed شده  $\epsilon$  عبارت  $T$  معادل را در نظر می‌گیریم:  $T \in \text{Integer}$  و  $\epsilon = \frac{1}{T}$

پس هر یک از  $n$  مورد  $[1, -1]$  با  $T$  قسمت تقسیم می‌کنیم. در این صورت  $n$  جعبه با ابعاد  $\frac{2}{T}$  خواصم داشت. حال دو نقطه  $x$  و  $x'$  را داخل یکی از این جعبه‌ها

در نظر بگیریم، برای  $\|x' - x\|$  خواهیم داشت:

$$\|x' - x\|^2 \leq \frac{4}{T^2} + \frac{4}{T^2} + \dots + \frac{4}{T^2} = \frac{4n}{T^2}$$

$$\Rightarrow \|x' - x\| \leq \frac{2\sqrt{n}}{T}$$

حال طبق خاصیت  $\rho$ -lipschitz داریم:

$$|f(x') - f(x)| \leq \rho \|x' - x\| \leq \frac{2\rho\sqrt{n}}{T}$$


حال اگر مقدار  $T$  را به اندازه کافی بزرگ در نظر بگیریم خواهیم داشت که:

$$T \rightarrow \infty : \lim_{T \rightarrow \infty} \frac{2\rho\sqrt{n}}{T} = 0 \Rightarrow |f(x') - f(x)| \approx 0$$

$$\Rightarrow f(x') \approx f(x)$$

در نتیجه مقادیر داخل هر جعبه به طور تقریبی ثابت هستند.

Approximate func :  $G(x) = \sum_{i=1}^n v_i \phi(w_i^T x + b_i)$



در لایه پنجم اول در واقع داریم مقادیر مختلف میانگین را به ازای وزن‌ها مختلف حساب می‌کنیم

سپس در لایه  $\sum$  از این میانگین‌ها Average می‌گیریم.



$$D_i^{(t+1)} = \frac{D_i^{(t)} e^{-w_t y_i h_t(x_i)}}{\sum_{j=1}^n D_j^{(t)} e^{-w_t y_j h_t(x_j)}}$$

در ابتدا داریم:

حال

$$\sum_i D_i^{(t+1)} \mathbb{I}_{[y_i h_t(x_i) = -1]} = \sum_{i: y_i h_t(x_i) = -1} D_i^{(t+1)}$$

الان باید اثبات کنیم که این عبارت بالا برابر با  $\frac{1}{2}$  است یا خیر.

$$\Rightarrow \sum_{i: y_i h_t(x_i) = -1} D_i^{(t+1)} = \frac{\sum_{i: y_i h_t(x_i) = -1} D_i^{(t)} e^{w_t}}{\sum_{i: y_i h_t(x_i) = -1} D_i^{(t)} e^{w_t} + \sum_{i: y_i h_t(x_i) \neq -1} D_i^{(t)} e^{-w_t}}$$

حال برای آنکه کسر بالا برابر با  $\frac{1}{2}$  شود، لازم است اثبات کنیم که دو عبارت در مخبر کسر با هم برابرند پس:

$$\sum_{i: y_i h_t(x_i) = -1} D_i^{(t)} e^{w_t} = \sum_{i: y_i h_t(x_i) \neq -1} D_i^{(t)} e^{-w_t} \Rightarrow \sum_{i: y_i h_t(x_i) = -1} D_i^{(t)} e^{w_t} = \sum_{i: y_i h_t(x_i) \neq -1} D_i^{(t)} e^{-w_t}$$

$$\sum_{i: y_i h_t(x_i) = -1} D_i^{(t)} e^{2w_t} = \sum_{i: y_i h_t(x_i) \neq -1} D_i^{(t)} = 1 - \sum_{i: y_i h_t(x_i) = -1} D_i^{(t)}$$

$$\Rightarrow (1 + e^{2w_t}) \underbrace{\sum_{i: y_i h_t(x_i) = -1} D_i^{(t)}}_{\epsilon_t} = 1$$

در حالت کافی است اثبات کنیم که عبارت  $(1 + e^{2w_t}) \epsilon_t$  برابر با یک است.

$$\underbrace{\left(1 + e^{2\left(\frac{1}{2} \log\left(\frac{1}{\epsilon_t} - 1\right)\right)}\right)}_{\frac{1}{\epsilon_t} - 1} \epsilon_t = \frac{1}{\epsilon_t} \cdot \epsilon_t = 1$$

در نتیجه حکم اثبات شد:

$$\sum_{i: y_i h_t(x_i) = -1} D_i^{(t+1)} = \frac{1}{2}$$